

國立陽明交通大學
數據科學與工程研究所
碩士論文

Institute of Data Science and Engineering
National Yang Ming Chiao Tung University
Master Thesis

MS-Net: 以考量重疊區域的損失函數訓練多尺度模型
對稀疏角度 CBCT 重建

MS-Net: Multi-Scale Network Trained with
Overlap-Based Loss for CBCT Reconstruction

研 究 生：楊忠霖 (Yang, Zhong-Lin)

指導教授：荊宇泰, 鄭昌杰 (Ching, Yu-Tai; Cheng, Chang-Chieh)

中華民國 一一四年四月

April 2025

MS-Net: 以考量重疊區域的損失函數訓練多尺
度模型對稀疏角度 CBCT 重建

MS-Net: Multi-Scale Network Trained with
Overlap-Based Loss for CBCT Reconstruction

研 究 生： 楊忠霖

Student : Zhong-Lin Yang

指導教授： 荊宇泰, 鄭昌杰 博士

Advisor : Dr. Yu-Tai Ching

Chang-Chieh Cheng

國立陽明交通大學

數據科學與工程研究所

碩士論文

A Thesis

Submitted to Institute of Data Science and Engineering

College of Computer Science

National Yang Ming Chiao Tung University

in partial Fulfillment of the Requirements

for the Degree of

Master of Science

in

Computer Science

April 2025

Taiwan, Republic of China

中華民國 一一四年四月

誌 謝

我要衷心感謝這段期間所有老師們的耐心指導與悉心教誨，無論是在課業上的提點，還是在研究方向上的引導，都給予我極大的幫助與啟發。正是因為有老師們的支持與鼓勵，我才能不斷成長、突破自己的限制，走到今天的這一步。

同時，我也要感謝一路以來陪伴在我身邊的同學們。在面對挑戰與壓力的時候，是你們的陪伴、互相打氣與交流，讓整段求學旅程充滿溫暖與回憶。無論是課堂討論、實驗合作，還是生活中的點滴相處，都成為我難以忘懷的寶貴經驗。

楊忠霖 於

國立陽明交通大學 數據科學與工程研究所

中華民國 一一四年四月

MS-Net: 以考量重疊區域的損失函數訓練多尺度模型對稀疏角度 CBCT 重建

學生：楊忠霖

指導教授：荊宇泰, 鄭昌杰 博士

國立陽明交通大學 數據科學與工程研究所 碩士班

摘要

X 光斷層掃描 (Computed Tomography, CT) 在包括醫學影像和病變檢測等眾多應用領域中具有重要意義。然而長時間暴露在高劑量的輻射中可能會損害人體細胞，以及增加採集數據的成本，並且增加罹患癌症以及相關疾病的風險。

因此目前主流的研究重點是尋找減少輻射劑量的方法。最簡單的減少劑量的方法是減少掃描次數，但這會導致投影 (Projection) 數量的減少，這種投影的減少可能會導致 CT 醫學演算法在重建的過程中出現影像解析度下降的情況，並使得影像受到 noise artifacts 的影響，圖像細節也可能會顯著的變得模糊。

為了解決這個問題，本文提出了一種基於深度學習的卷積神經網路 (CNN, Convolutional Neural Network) 模型的方案，對於傳統的 U-Net 進行小幅度的改動，並透過對 sinogram 以及 volume 的調整，來減少重建時 noise artifacts 的影響程度。

除了對模型的調整，我們設計了 input 跟 weight 的架構，使得 loss function 的計算方式跟傳統的深度學習不一樣。

關鍵字：Deep learning, sparse-view computed tomography (SVCT) reconstruction, Convolutional Neural Network (CNN), Unet, cone beam computed tomography (CBCT)

MS-Net: Multi-Scale Network Trained with Overlap-Based Loss for CBCT Reconstruction

Student : Zhong-Lin Yang Advisor: Dr. Yu-Tai Ching
Chang-Chieh Cheng

Institute of Data Science and Engineering
National Yang Ming Chiao Tung University

Abstract

Computed Tomography (CT) plays a significant role in various applications, including medical imaging and lesion detection. However, prolonged exposure to high doses of radiation can damage human cells, increase data acquisition costs, and elevate the risk of cancer and related diseases.

As a result, current mainstream research focuses on reducing radiation dose. The most straightforward approach is to reduce the number of scans, but this leads to a decrease in the number of projections. Fewer projections can result in degraded image resolution during CT reconstruction and make the images more susceptible to noise artifacts, potentially causing significant blurring of image details.

To address this issue, this paper proposes a solution based on a deep learning Convolutional Neural Network (CNN) model. We introduce slight modifications to the traditional U-Net architecture and apply adjustments to both the sinogram and the reconstructed volume to reduce the impact of noise artifacts during reconstruction.

In addition to modifying the model, we designed a custom structure for the input and weights, resulting in a loss function that differs from those used in traditional deep learning approaches.

Keywords: Deep learning, sparse-view computed tomography (SVCT) reconstruction, Convolutional Neural Network (CNN), Unet, cone beam computed tomography(CBCT).



Contents

Chinese Abstract	i
English Abstract	ii
Contents	iv
List of Figures	vi
List of Tables	viii
1 Introduction	1
2 Related Work	3
3 Method	6
3.0.1 Data preprocessing	7
3.0.2 Model	7
3.0.3 Loss function	7
3.0.4 Projection domain	9
3.0.5 Image domain	10
4 Experiments and results	15
5 Conclusions	23



List of Figures

Figure 1	Projection domain 的架構	11
Figure 2	Image domain 的架構	11
Figure 3	workflow, 輸入的 sparse-view projection(100 張) 經過 projection domain 對 projection 處理三次以後, 變成 full-view projection(800 張), 經過 FDK 演算法將其重建成 volume, 再將 volume 放入 image domain 做處理, 即可完成重建	11
Figure 4	UNet 模型的架構, 其中 (32, 32, 32, 1) 的輸入代表的是一個 (32, 32, 32) 的 patch, 其中 channel 為 1	12
Figure 5	MultiBlock, projection domain 第一個輸入的模型模塊的架構, 其中 (32, 32, 32, 1) 的輸入代表的是一個 (32, 32, 32) 的 patch, 其中 channel 為 1, 輸出時會變成 (32, 64, 32) 的尺寸, 放大的維度是 views 也就是 projection 的張數, 在做 concatenate 時會先對其做 upsampling	12
Figure 6	overlapping 的設計原理, (M, N, D) 分別代表 projection/volume 的長度、寬度、深度, 其中 input 是模型的輸入 projection/volume, target 是 projection/volume ground truth, output 是模型的輸出加總, weight 是模型輸出加總時生成的對應權重	13
Figure 7	訓練時會先將 weight 預設為 0, 並在 input/target 切割第一個 patch, size 為 (32, 32, 32), 將其放入模型後得到的輸出, 會放置在 output 的對應位置	13
Figure 8	將輸出的 patch 放入 output 時, weight 會更新, 對應位置的值會加一	13

Figure 9	訓練第二個 patch 時做法跟第一個 patch 相同，但是兩個相鄰的 patch 之間會有 overlap，在此設為 16 個單位，此時可以看見重疊部分的 weight 被更新為 2，其中 output 重疊的部分採用相加的方式處理	14
Figure 10	a. 顯示的是資料集 (頭顱) 的 Ground truth，b. 顯示的是 MSNet 的測試結果，c. 顯示的是 HDNet 的測試結果，d. 顯示的是 SS(Sinogram Synthesis) 的測試結果, e. 顯示的是使用 FDK 演算法對 100 張 projection 直接重建, f. 顯示的是 100 個 views upsampling 成 800 個 views 重建	17
Figure 11	本圖顯示的是實驗結果的 sinogram	18
Figure 12	a. 顯示的是資料集 (胸腔) 的 Ground truth，b. 顯示的是 MSNet 的測試結果，c. 顯示的是 HDNet 的測試結果，d. 顯示的是 SS(Sinogram Synthesis) 的測試結果	19
Figure 13	顯示了 MSNET projection domain 中 projection 逐漸放大的過程，可以看出隨著 views 的增加，重建的影像品質也更加清晰	20

List of Tables

Table 1	不同比較方法的意義，包含了本文的 MSNET，以及做為比較對象的 HDNET 與 Sinogram Synthesis，用以說明本文提出的 MSNET 方法優於現有的 UNET 相關的論文。還有傳統的 FDK 演算法，其中 FDK 演算法分別使用了 100 個 views 以及將 100 個 views upsampling 成 800 個 views，在此為了說明深度學習的方法能優於傳統的 FDK 演算法。最後，還有僅使用 projection domain 的 MSNET(Single domain)，用來說明使用兩個 domain 的有效性。	21
Table 2	本次實驗所得到的 ssim、psnr，包含了本文的 MSNET，以及做為比較對象的 HDNET 與 Sinogram Synthesis，傳統的 FDK 演算法，還有僅使用 projection domain 的 MSNET(Single domain)	21
Table 3	本次實驗所得到的 ssim、psnr，包含了本文的 MSNET，以及做為比較對象的 HDNET 與 Sinogram Synthesis，傳統的 FDK 演算法	22
Table 4	顯示了 MSNET projection domain 中 projection 逐漸放大的過程，可以看出隨著 views 的增加，對應的 ssim、psnr 可以看出有越來越好的趨勢。	22

Chapter 1. Introduction

在處理 sparse-view computed tomography (SVCT) 問題時，傳統上大多數研究者會採用經典的影像重建演算法，例如最為人所熟知的 Filtered Back Projection (FBP) [1]。這類傳統方法具有實作簡單與計算效率高的優勢，然而在視角數量極為稀疏的情境下，這些演算法往往會受到嚴重的雜訊 (artifacts) 影響，導致最終影像產生模糊、結構變形等問題，尤其對於醫學影像中那些細微且關鍵的人體組織結構 (例如胸腔內部的肺部細節) 會造成資訊遺失，進而影響臨床診斷的準確性。因此，為了提升重建影像的品質與真實性，現今主流研究逐漸轉向應用深度學習技術，透過神經網路學習影像中的非線性特徵與空間關聯性，以達成更高品質且更具魯棒性的重建效果。

在本文所提出的方法中，我們設計了一個結合 projection domain 與 image domain 雙階段處理流程的重建架構，並在資料前處理 (data preprocessing) 的階段引入了 ASTRA toolkit [2] 來模擬並生成高品質的投影影像 (projection) 作為 Ground Truth。具體而言，我們首先針對原始 volume 資料，透過 ASTRA 工具模擬產生 800 張視角的投影影像 (projection)，作為最完整的全視角 Ground Truth 資料集。接著，為了模擬不同程度的視角稀疏情況，我們使用三線性插值 (Trilinear Interpolation) 技術，將這 800 張投影影像 (projection) 下採樣 (downsampling) 為 400 張、200 張與 100 張，分別對應不同稀疏等級的輸入資料。

這些低視角的投影影像將首先通過我們設計的深度學習模型，在 projection domain 中進行補全與還原，使其恢復為與 Ground Truth 相同數量的 800 張投影影像。隨後，這些

還原後的投影影像會透過 FDK (Feldkamp, Davis, and Kress) 演算法進行三維重建，轉換為對應的 volume。最後，我們將重建得到的 volume 與原始 Ground Truth volume 一同輸入至另一個 volume domain 模型，進一步精細化地進行學習與雜訊 (artifacts) 抑制處理，以獲得最終的高品質重建結果。

在實驗設計方面，我們選用了三個具代表性的資料集進行評估，分別包含兩個胸腔 (chest) 資料集以及一個頭顱 (head) 資料集。所有資料皆使用相同的 ASTRA-based 投影生成方式建立 Ground Truth，並依照上述比例進行下採樣 (downsampling)。模型訓練過程中，我們採用了 Adam optimizer 作為優化器，並以均方誤差 (Mean Squared Error, MSE) 作為損失函數來監控模型學習進度與收斂效果。

總結本研究的實驗結果可發現，所提出的方法在重建品質上相較於現有的研究，如 Lee, Hoyeon 等人提出的 residual U-Net 架構 [3]，以及 Hu, Dianlin 等人結合插值 (Interpolation) 與 CNN 的混合方法 [4]，均展現出更為優異的表現。我們所提出模型的 loss value 更低，同時在兩項主要的影像品質評估指標——結構相似度指標 (SSIM) 與峰值訊噪比 (PSNR) 上也取得了明顯更高的分數，顯示本方法在有效還原結構細節與抑制雜訊方面皆具顯著優勢。

Chapter 2. Related Work

在現有的相關文獻中，許多研究者針對利用深度學習進行影像重建的主題已提出多種創新的模型與方法。當前主流的深度學習架構如卷積神經網路（Convolutional Neural Networks, CNN）[5]、U-NET[6] 與 Transformer[7]，廣泛應用於醫學影像重建任務中。這些方法在處理稀疏視角或低劑量掃描所產生的雜訊（artifacts）時展現出強大的能力，相較於傳統的影像重建演算法如濾波反投影（Filtered Back Projection, FBP）[1]、FDK（Feldkamp-Davis-Kress）[8] 演算法，能有效提升最終影像的品質與細節保留度。

濾波反投影（Filtered Back Projection, FBP）[1] 為最經典的影像重建方法之一，其理論與實作流程已由 Kak 與 Slaney 於《Principles of Computerized Tomographic Imaging》一書中系統性地整理與闡述，至今仍廣泛作為 CT 重建的理論基礎教材。

FDK（Feldkamp-Davis-Kress）演算法 [8] 為 Feldkamp 等人於 1984 年提出，首次針對圓軌跡錐形束幾何（circular cone-beam geometry）設計實用的三維影像重建演算法。該方法將傳統 FBP 理論拓展至三維 cone-beam CT 系統，透過加權與投影 (projection) 補正，有效解決了非平行投影造成的扭曲與失真。由於其運算速度快、實作簡單，FDK 成為目前臨床牙科 CBCT 與工業檢測中最常用的標準演算法。

卷積神經網路（Convolutional Neural Networks, CNN）[5] 最早由 LeCun 等人於 1990 年代提出，並於其經典論文 Gradient-Based Learning Applied to Document Recognition 中完整闡述了 CNN 架構與訓練方式。該研究提出了 LeNet-5 架構，成功應用於手寫數字辨識（如 MNIST）任務，成為深度學習應用於圖像辨識的開端。LeNet-5 結合了卷積層、池化層與全連接層，並透過反向傳播演算法進行訓練，證明了神經網路具備自動特徵學習與端對端訓練的能力。該架構為後續深度 CNN（如 AlexNet、VGG、ResNet 等）

奠定了基礎，對深度學習領域影響深遠。

Transformer [7] 架構最早由 Vaswani 等人於 2017 年提出，其開創性的研究 Attention is All You Need 徹底改變了序列建模 (Sequence Modeling) 與自然語言處理 (Natural Language Processing, NLP) 的發展方向。該架構完全移除了傳統序列模型中的遞迴與卷積結構，改以 Multi-head Self-Attention 為核心，能同時處理整段序列中的全域關係。Transformer 不僅大幅提升了機器翻譯等語言任務的準確率，同時具備高度並行化的特性，成為日後 BERT、GPT、ViT 等多種模型的基礎架構，在圖像與醫學等多領域皆有廣泛應用。

Pan, Jiayi 等人所提出的方法 [9] 是基於 Transformer 架構所設計的一種多尺度學習模型，專門用於提升 CT 胸腔影像的重建效果。該研究在胸腔資料集上進行實驗，結果顯示其模型在多個指標上均明顯優於傳統的 FBP 方法以及先前提出的深度學習模型 HDNet，證明了 Transformer 在捕捉全域特徵與建構相關資訊方面的優勢。

Lee, Hoyeon 等人 [3] 則提出了一種創新的 sinogram-domain 架構，該方法針對原始 sinogram 資料進行處理，並針對 U-Net 架構進行優化。他們將標準 U-Net 修改為具有殘差連接的 residual U-Net，以加強網路的穩定性與深層特徵的傳遞能力。透過在胸腔 CT 資料集上的實驗，該方法展示了優異的重建品質，特別是在細節還原與雜訊 (artifacts) 抑制方面成效顯著。

Hu, Dianlin 等人 [4] 則嘗試將傳統插值 (Interpolation) 技術與現代深度學習方法相結合，提出了一種混合式重建模型。該方法先利用插值方式對稀疏 sinogram 進行初步補全，再透過 CNN 模型進行精細重建，以提升重建結果的真實性與連貫性。實驗證實，在胸腔影像的重建任務中，該混合模型的效能大幅優於傳統的 FDK (Feldkamp-Davis-Kress) 演算法。

Zha, Ruyi、Zhang, Yanhao 與 Li, Hongdong 等人於 2022 年提出了一種基於深度學習編碼器的重建方法 [10]，該方法使用了具備學習能力的 encoder 架構，能有效地從輸入資料

中提取潛在特徵並還原高品質影像。他們所提出的 NAF-based 模型不僅在當年度取得最先進（state-of-the-art）的準確率表現，也在多項評估指標上超越現有方法，證明其在醫學影像重建領域的潛力與應用價值。

Xie 等人在 2018 年針對 sparse-view computed tomography（SVCT）所產生的 artifact 問題，提出一種基於改良版 GoogLeNet 的深度學習方法 [11]，以殘差學習（residual learning）方式訓練神經網路來預測重建影像中的 artifact，進而將其從輸入圖像中扣除。該方法利用多層 inception 模組以提取不同尺度的特徵資訊，並在多組臨床資料上實驗證明，其在 PSNR 與 SSIM 指標上皆優於傳統的 FBP 與 ASD-POCS 方法。此外，推論時間顯著低於傳統迭代方法，顯示其在提升 SVCT 影像品質與計算效率上的潛力。



Chapter 3. Method

本文使用具有將 sinogram 單一維度放大兩倍的功能的模型，將輸入的 sparse view sinogram 的單一維度 (角度) 放大兩倍，並將模型輸出的結果重新輸入到下一個模型訓練，直到輸出的 size 變成跟 full view 一樣的大小，不同的 size 會用不同的模型來訓練，但其架構都是一樣的，這個做法在本文稱其為 multi scale。當 sinogram 跟 full view 一樣大時，使用一個非放大功能的模型對其做訓練，使其輸出跟 target 更接近的 sinogram，這個做法可以消除 sinogram 上的雜訊。

當 sinogram 得到修正後，使用 ASTRA toolkit[2] 的 FDK(Feldkamp, Davis, and Kress) 演算法，將其重建為三維 volume，供後續的模型對其做訓練並消除其雜訊。

最後，將得到的 image 跟原始的 volume 做訓練，用於消除 volume 上的雜訊，最後得到的結果即為 MSNet 最終的重建結果。

由於訓練用的 data 過於龐大，使得 GPU 記憶體無法容納，故無法直接輸入至模型中，因此本文採用了特殊的切割與重疊方法，將 data 與 target 一一切割成 $32 \times 32 \times 32$ 的 patch 後做配對進行 loss 計算，且計算的 loss 是 patch 跟 patch 重疊後的結果，這樣的做法可以有效地減少 patch 跟 patch 之間的雜訊，如果 patch 跟 patch 之間沒有重疊，在察看 volume 時很容易發現網格狀的正方形雜訊。

在 Figure 3 中可以看到本文提出的方法的流程圖。

3.0.1 Data preprocessing

我們的 raw data 是兩組胸腔與一組頭顱的三維 volume，為了進行 Sparse-View Computed Tomography (SVCT) 的實驗，我們將 volume 分成三組，每一組內的每個 volume 分別用 ASTRA toolkit[2] 模擬出 800 個角度的 projection，再將其做 downsampling(trilinear interpolation) 成 100 個、200 個、400 個角度，做為實驗的輸入 data 使用，以便用來評估其重建結果。

3.0.2 Model

本文使用的是一種基於深度學習的卷積神經網路 (CNN, Convolutional Neural Network) 模型，其構造類似於經典的 3D UNET，其中的 pooling layers 改成用 convolutions layers 有更好的學習效果，並在其輸入端加入了對特定維度放大兩倍的結構，使其具有放大的功能，並加入 residual 的設計，使得模型擁有更好的訓練成果，之所以選擇用 3D UNET 而不是 2D UNET 是因為 sinogram 與 volume 是三維的，且他們在三個維度內的相鄰組織皆有相關性，因此為了更好的重建效果，我們採用 3D UNET 來保留住 sinogram 與 volume 三個維度的特徵。

在 Figure 4 中我們可以看到本文模型的架構。

3.0.3 Loss function

本文使用的 loss function 為 MSE(Mean Squared Error)，在 projection domain 跟 image domain 的模型訓練中皆使用此 loss function，並且融合了 overlapping 的設計，強化了

loss function 的效果，其算式如下所示：

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \frac{y'_i}{w_i})^2 \quad (3.1)$$

其中 n 是所有輸入資料的數量, y_i 是 ground truth 中的一小塊 patch, y'_i 是模型的預測值總和中的一小塊 patch(相對的位置跟 ground truth 一樣), w_i 是在加總模型預測值時生成的權重中的一小塊 patch(相對的位置跟 ground truth 一樣)

在 Figure6 可以看到 overlapping 的原理，由於輸入的 projection/volume 尺寸過大，無法將其整體放入模型訓練，所以會將其切割成小 patch，本文設置的 patch size 為 (32, 32, 32)，且 patch 和相鄰的 patch 會重疊 16 個單位。在 projection/volume domain 進行訓練時，會將 (M, N, D) 尺寸的 input 切割成一個個 (32, 32, 32) 的 patch，將此 patch 放入模型後會生成出 (32, 32, 32) 的輸出，此時會有一個 (M, N, D) 尺寸的 output 容納這個 (32, 32, 32) 的 patch，patch 放置的位置與 input 中取出 patch 的位置相同，同時有一個 (M, N, D) 尺寸的 weight，在同樣的對應位置中 +1，表示在該位置放置了 1 個 patch，之後再將 output 除以 weight，最後才會使用 loss function 計算跟 ground truth 的 loss 值。詳細的過程可以參考 Figure7、Figure8、Figure9。

首先，訓練時會先將 weight 預設為 0，並在 input/target 切割第一個 patch，size 為 (32, 32, 32)，將其放入模型後得到的輸出，會放置在 output 的對應位置。再來，將輸出的 patch 放入 output 時，weight 會更新，對應位置的值會加一。最後，訓練第二個 patch 時做法跟第一個 patch 相同，但是兩個相鄰的 patch 之間會有 overlap，在此設為 16 個單位，此時可以看見重疊部分的 weight 被更新為 2，此即為 overlap 的設計原理。

3.0.4 Projection domain

在這個 domain 中，輸入的是 sparse-view projection，輸入的 projection 會先經過一個小的放大模型，將 projection 的 view 維度放大兩倍，也就是將 projection 的張數放大兩倍，然後再將放大兩倍的 projection 放入 Figure4 的模型，最後將會輸出 view 維度放大兩倍的結果。

在該階段的資料輸入中，我們採用了滑動視窗（sliding window）結合重疊區塊（overlapping patch）的方式進行分割與處理。具體而言，將完整的三維 volume 資料拆分為大小為 (32, 32, 32) 的小立方體（patch），並在每個維度上套用固定重疊單位為 16 的重疊策略。這樣的設計可有效減少 patch 邊界處的不連續問題，避免因切割造成的偽影 (artifact)，並且藉由重疊區的多次預測達到結果平滑化的效果。此外，此策略亦有助於模型在訓練與推論階段對大尺寸資料的處理，提升訓練效率與 GPU 記憶體的使用彈性。所有預測的 patch 會在推論結束後進行加權融合，形成最終完整的重建 projection，使得大尺寸的資料也可以被完全的處理，以下有更詳細的圖解說明。

在 Figure1 中顯示的是 Projection domain 的架構，在 Figure5 中可以看到第一個輸入的模型模塊 (MultiBlock)，其中在做 concatenate 時會先對其做 upsampling，這個模塊的輸出才會再輸入至 Figure4 的模型 (UNet) 中。

在此階段的 overlap 是採用 (32, 64, 32) 的尺寸做重疊，overlap 的單位仍然是 16，唯獨在 views 這個維度上，overlap 的單位是 32。

3.0.5 Image domain

Image domain 階段，輸入資料的型態為完整的三維體積影像 (volume)，這些 volume 為經過 projection domain 處理與初步重建後的結果。這些 volume 資料將被送入我們所設計的深度學習模型中，如圖 4 所示。該模型架構基於改良的 3D U-Net 結構，結合殘差連接與多尺度特徵融合機制，具有高度表現力與重建能力，特別適合處理稀疏視角投影所產生的不完整三維結構。

圖 2 則呈現了 Image domain 中所使用的模型架構細節，包括編碼與解碼路徑的層級安排、特徵維度變化、殘差模組的位置安排等。該架構可有效學習 volume 中的空間關聯性與局部結構，進而提高重建精度，並減少傳統重建方法中常見的模糊與雜訊干擾。

在此階段仍然採用 Projection domain 使用的滑動視窗 (sliding window) 結合重疊區塊 (overlapping patch) 的方式進行分割與處理，在此使用的 patch 大小為 (32, 32, 32)，重疊的尺寸為 16。




Figure 1: Projection domain 的架構




Figure 2: Image domain 的架構




Figure 3: workflow，輸入的 sparse-view projection(100 張) 經過 projection domain 對 projection 處理三次以後，變成 full-view projection(800 張)，經過 FDK 演算法將其重建成 volume，再將 volume 放入 image domain 做處理，即可完成重建




Figure 4: UNet 模型的架構，其中 (32, 32, 32, 1) 的輸入代表的是一個 (32, 32, 32) 的 patch，其中 channel 為 1




Figure 5: MultiBlock，projection domain 第一個輸入的模型模塊的架構，其中 (32, 32, 32, 1) 的輸入代表的是一個 (32, 32, 32) 的 patch，其中 channel 為 1，輸出時會變成 (32, 64, 32) 的尺寸，放大的維度是 views 也就是 projection 的張數，在做 concatenate 時會先對其做 upsampling




Figure 6: overlapping 的設計原理，(M, N, D) 分別代表 projection/volume 的長度、寬度、深度，其中 input 是模型的輸入 projection/volume，target 是 projection/volume ground truth，output 是模型的輸出加總，weight 是模型輸出加總時生成的對應權重




Figure 7: 訓練時會先將 weight 預設為 0，並在 input/target 切割第一個 patch，size 為 (32, 32, 32)，將其放入模型後得到的輸出，會放置在 output 的對應位置




Figure 8: 將輸出的 patch 放入 output 時，weight 會更新，對應位置的值會加一




Figure 9: 訓練第二個 patch 時做法跟第一個 patch 相同，但是兩個相鄰的 patch 之間會有 overlap，在此設為 16 個單位，此時可以看見重疊部分的 weight 被更新為 2，其中 output 重疊的部分採用相加的方式處理

Chapter 4. Experiments and results

本文的實驗中，HDNET[4]、Sinogram Synthesis[3]、MSNET 都是用 MSE LOSS、ADAM optimizer，並且配合本文設計的重疊演算法，以及拆分 patch 的設計，來完成所有的實驗，為了完成 sparse-view CBCT 重建實驗，在此實驗中的所有方法使用的 views 皆為 100，使用的資料集分別為兩種胸腔與一種頭顱，訓練的數量為 25 組，測試的數量為 3 到 5 組，其中 projection 的生成使用的是 astra-toolbox 演算法，模擬出真實的拍攝場景，以生成必要的 projection 資料。

使用的 GPU 是一張 NVIDIA GeForce RTX 4090、作業系統是 linux ubuntu 20.04.6 LTS (Focal Fossa)、CPU 12th Gen Intel(R) Core(TM) i7-12700。

套件使用的版本為:astra-toolbox 2.1.0、numpy 1.26.4、Python 3.12.3、GCC 12.3.0、conda 23.1.0、cuda 12.1。

Table 1 提供了各實驗方法的意義與說明，其中包含了本文的 MSNET，以及做為比較對象的 HDNET[4] 與 Sinogram Synthesis[3]，用以說明本文提出的 MSNET 方法優於現有的 UNET 相關的論文。還有傳統的 FDK 演算法，其中 FDK 演算法分別使用了 100 個 views 以及將 100 個 views upsampling 成 800 個 views，在此為了說明深度學習的方法能優於傳統的 FDK 演算法。最後，還有僅使用 projection domain 的 MSNET(Single domain)，用來說明使用兩個 domain 的有效性。

Table 2 呈現了本次實驗所得到的 ssim、psnr，包含了本文的 MSNET，以及做為比較對象的 HDNET 與 Sinogram Synthesis，傳統的 FDK 演算法，其中 FDK 演算法分別使用了 100 個 views 以及將 100 個 views upsampling 成 800 個 views，還有僅使用 projection domain 的 MSNET(Single domain)。

Table 10 顯示了各方法所產生的重建結果，包含了本文的 MSNET，以及做為比較對象的 HDNET 與 Sinogram Synthesis。

Table 4 跟 Table 13 則顯示了 MSNET projection domain 中 projection 逐漸放大的過程，可以看出隨著 views 的增加，重建的影像品質也更加清晰，對應的 ssim、psnr 也可以看出有越來越好的趨勢。

Table 3 則顯示了 MSNET 與 FDK 演算法的重建結果比較，用以說明此深度學習的方法可以優於傳統 FDK 演算法。




Figure 10: a. 顯示的是資料集 (頭顱) 的 Ground truth，b. 顯示的是 MSNet 的測試結果，c. 顯示的是 HDNet 的測試結果，d. 顯示的是 SS(Sinogram Synthesis) 的測試結果, e. 顯示的是使用 FDK 演算法對 100 張 projection 直接重建, f. 顯示的是 100 個 views upsampling 成 800 個 views 重建




Figure 11: 本圖顯示的是實驗結果的 sinogram




Figure 12: a. 顯示的是資料集 (胸腔) 的 Ground truth，b. 顯示的是 MSNet 的測試結果，c. 顯示的是 HDNet 的測試結果，d. 顯示的是 SS(Sinogram Synthesis) 的測試結果




Figure 13: 顯示了 MSNET projection domain 中 projection 逐漸放大的過程，可以看出隨著 views 的增加，重建的影像品質也更加清晰

Abbreviation	method
HDNet[4]	採用非 Residual 的 3D U-Net 模型，我們首先使用 projection 資料進行初步訓練。 接著，使用 ASTRA toolkit 提供的 FDK 演算法進行重建。 最後將重建後的結果再與原始的 volume 進行再訓練。
SS (Sinogram Synthesis)[3]	採用 Residual 3D U-Net 模型，我們首先使用 projection 資料進行初步訓練。 接著，使用 ASTRA toolkit 提供的 FDK 演算法進行重建。 最後將重建後的結果再與原始的 volume 進行再訓練。
SD (Single domain)	僅使用 Residual 3D U-Net 對 projection 資料進行訓練，其中使用的模型是 MSNet，也就是僅有 projection domain 的 MSNet。
FDK	Feldkamp, Davis, and Kress 演算法，從傳統的二維 Filtered Back Projection (FBP) 發展而來，用來處理 3D cone beam CT 資料的重建。它是目前醫學影像（如牙科、胸腔 CT）和工業檢測中非常常見的重建方法
FDK(100 views)	使用 FDK 演算法對 100 張 projection 直接重建。
FDK(*800 views)	使用 FDK 演算法對 100 張 projection upsampling 成 800 張 projection 的結果重建。
Our work	採用 Residual 3D U-Net 具有放大兩倍功能的模型與 Residual 3D U-Net，我們首先使用 projection 資料對 Residual 3D U-Net 具有放大兩倍功能的模型進行初步訓練。 接著，透過 ASTRA toolkit 提供的 FDK 演算法進行重建 [2]。 最後將重建後的結果再與原始的 volume 對 Residual 3D U-Net 進行訓練。

Table 1: 不同比較方法的意義，包含了本文的 MSNET，以及做為比較對象的 HDNET 與 Sinogram Synthesis，用以說明本文提出的 MSNET 方法優於現有的 UNET 相關的論文。還有傳統的 FDK 演算法，其中 FDK 演算法分別使用了 100 個 views 以及將 100 個 views upsampling 成 800 個 views，在此為了說明深度學習的方法能優於傳統的 FDK 演算法。最後，還有僅使用 projection domain 的 MSNET(Single domain)，用來說明使用兩個 domain 的有效性。

Method	MAE	MSE	ssim	psnr
HDNet	0.0267	0.0017	0.8218	29.1137
SS	0.0270	0.0016	0.8541	28.9320
SD	0.0302	0.0026	0.7883	27.5226
MSNet	0.0250	0.0016	0.8758	30.2163

Table 2: 本次實驗所得到的 ssim、psnr，包含了本文的 MSNET，以及做為比較對象的 HDNET 與 Sinogram Synthesis，傳統的 FDK 演算法，還有僅使用 projection domain 的 MSNET(Single domain)

Method	MAE	MSE	ssim	psnr
HDNet	0.0267	0.0017	0.8218	29.1137
SS	0.0270	0.0016	0.8541	28.9320
FDK(100 views)	0.0387	0.0041	0.5588	24.3806
FDK(*800 views)	0.0330	0.0029	0.7672	26.8750
MSNet	0.0250	0.0016	0.8758	30.2163

Table 3: 本次實驗所得到的 ssim、psnr，包含了本文的 MSNET，以及做為比較對象的 HDNET 與 Sinogram Synthesis，傳統的 FDK 演算法

Method	MAE	MSE	ssim	psnr
100views	0.0387	0.0041	0.5588	24.3806
200views	0.0331	0.0028	0.7175	26.6313
400views	0.0313	0.0027	0.7720	27.2304
800views	0.0302	0.0026	0.7883	27.5226

Table 4: 顯示了 MSNET projection domain 中 projection 逐漸放大的過程，可以看出隨著 views 的增加，對應的 ssim、psnr 可以看出有越來越好的趨勢。

Chapter 5. Conclusions

本研究針對經典的 3D U-Net 架構進行深度設計與擴展，目標在於解決 Sparse-View Computed Tomography (SVCT) 重建問題。SVCT 是一種具挑戰性的重建問題，特別在醫學影像領域中，僅能取得有限角度的投影 (projection) 數據時，重建出的三維影像 (volume) 常伴隨嚴重的失真與結構模糊。因此，我們提出的改良式 3D U-Net 架構，不僅保留了原始 U-Net 的對稱性與多尺度特性，還針對胸腔與頭顱等典型資料集進行調整與優化，使得模型能夠更穩定且有效地適應不同類型的臨床影像數據。


在架構設計上，我們進一步引入了殘差連接 (residual connections)，使得資訊在網路中能夠更順暢地傳遞，降低梯度消失的風險，並提升模型在訓練階段的收斂速度與準確度。透過殘差設計，模型的非線性表達能力得以強化，使其在進行稀疏視角 (Sparse-View) 影像的特徵提取與重建時，能夠捕捉更多關鍵結構與細節。

此外，我們結合了 HDNet 與 Sinogram Synthesis (SS) 兩種方法的核心優勢，設計出一種全新的 multi scale 的深度學習架構。該架構引入一個具有放大兩倍功能的模塊，能夠在 projection domain 中將稀疏角度 (Sparse-View) 的投影 (projection) 資料補全至更高解析度，進而提升最終影像的品質。我們亦加入了重疊 (overlap) 演算法，藉由不同區塊的交疊訓練，有效減緩了 patch-based 訓練過程中常見的邊界不連續問題，也就是網格狀的 artifact。同時，在訓練資料的處理方面，採用了 patch 拆分與重組策略，使模型能夠處理更大尺寸的三維資料，並提升 GPU 記憶體使用的效率。

實驗結果顯示，本研究所提出的方法在 PSNR、SSIM 等評估指標上皆顯著優於目前主流的重建方法，提升幅度約為 1~3 個百分點；同時在重建結果的視覺品質上，也展現出更少的網格狀 artifact 與更清晰的組織邊界。綜合來看，本研究的方法不僅具有良好的泛化能力與重建精度，更展現出在實際醫學應用中推廣的潛力。



References

- 
- [1] A. C. Kak and M. Slaney, *Principles of computerized tomographic imaging*. IEEE Press, 1988, reprinted by SIAM in 2001, available at <https://web.eecs.umich.edu/~fessler/book/>.
- [2] “Astra toolbox,” <https://www.astra-toolbox.com/>, 2022, version 2.1 [Software].
- [3] H. Lee, J. Lee, H. Kim, B. Cho, and S. Cho, “Deep-neural-network-based sinogram synthesis for sparse-view ct image reconstruction,” *IEEE Transactions on Radiation and Plasma Medical Sciences*, vol. 3, no. 2, pp. 109–119, 2018.
- [4] D. Hu, J. Liu, T. Lv, Q. Zhao, Y. Zhang, G. Quan, J. Feng, Y. Chen, and L. Luo, “Hybrid-domain neural network processing for sparse-view ct reconstruction,” *IEEE Transactions on Radiation and Plasma Medical Sciences*, vol. 5, no. 1, pp. 88–98, 2020.
- [5] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, “Gradient-based learning applied to document recognition,” *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278–2324, 1998.
- [6] O. Ronneberger, P. Fischer, and T. Brox, “U-net: Convolutional networks for biomedical image segmentation,” in *Medical image computing and computer-assisted intervention—MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III* 18. Springer, 2015, pp. 234–241.
- [7] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention is all you need,” 2023. [Online]. Available: <https://arxiv.org/abs/1706.03762>

- [8] L. A. Feldkamp, L. C. Davis, and J. W. Kress, "Practical cone-beam algorithm," *JOSA A*, vol. 1, no. 6, pp. 612–619, 1984.
- [9] J. Pan, H. Zhang, W. Wu, Z. Gao, and W. Wu, "Multi-domain integrative swin transformer network for sparse-view tomographic reconstruction," *Patterns*, vol. 3, no. 6, 2022.
- [10] R. Zha, Y. Zhang, and H. Li, "Naf: neural attenuation fields for sparse-view cbct reconstruction," in *International Conference on Medical Image Computing and Computer-Assisted Intervention*. Springer, 2022, pp. 442–452.
- [11] S. Xie, X. Zheng, Y. Chen, L. Xie, J. Liu, Y. Zhang, J. Yan, H. Zhu, and Y. Hu, "Artifact removal using improved googlenet for sparse-view ct reconstruction," *Scientific reports*, vol. 8, no. 1, p. 6700, 2018.

